Общая концепция

Глобально логика приложения разделена на 2 составляющие: backend и frontend. В infra-dev/ и infra/ располагаются файлы для локального развертывания при разработке и развертывания на сервере.

SERVICE/

├── backend

├── frontend

└── infra-dev

└── infra

Для запуска контейнеров локально нужно в директории SERVICE/infra-dev/ создать файл .env и поместить туда переменные из .env.dev.template, затем выполнить:

docker compose up -d

Backend (FastApi)

Общее

Серверная часть реализует основную логику приложения и предоставляет эндпоинты для фронтенда.

Техническая часть

Основные технические особенности:

- Контейнеризация
- Логирование
- Асинхронность
- Мультипроцессинг

Структура:

SERVICE/backend/

```
├── Dockerfile
├── api
│   ├── __init__.py
│   ├── utils.py
│   └── v1
│       ├── __init__.py
│       ├── background_tasks.py
│       └── trainer.py
├── dependency.py
├── exceptions.py
├── main.py
├── models
│   └── default
│       ├── model_lr_e.cloudpickle
│       ├── model_mnb_e.cloudpickle
│       └── model_svc_e.cloudpickle
├── requirements.txt
├── serializers
│   ├── __init__.py
│   ├── background_tasks.py
│   ├── trainer.py
│   └── utils
│       ├── __init__.py
│       └── trainer.py
├── services
```

```
│   ├── __init__.py
│   ├── background_tasks.py
│   ├── trainer.py
│   └── utils
│       ├── __init__.py
│       └── trainer.py
├── settings
│   ├── __init__.py
│   └── app_config.py
└── store.py
```

Описание основных компонент:

1. `SERVICE/backend/main.py`
   Entrypoint приложения, отвечает за запуск FastAPI сервера и осуществляет подготовку перед этим (загружает модели по умолчанию в память и создает общий пул процессов).
2. `SERVICE/backend/services`
   Здесь реализован сервисный слой:
   - `trainer.py`: логика, связанная с моделями
   - `background_tasks.py`: логика, связанная с хранимой информацией о фоновых задачах

   В SERVICE/backend/services/utils находятся вспомогательные функции
3. `SERVICE/backend/serializers`
   Тут реализованы pydantic схемы для сериализации/десериализации данных. Разделение по файлам аналогично сервисному слою.
4. `SERVICE/backend/api`
   Содержит реализацию эндпоинтов
5. `SERVICE/backend/Dockerfile`
   Описание Docker-образа для контейнеризации приложения
6. `SERVICE/backend/models`
   Директория, в которой хранятся файлы всех обученных моделей
7. `SERVICE/backend/settings`
   Здесь находятся настройки приложения

8. `SERVICE/backend/store.py`
   Данный файл представляет из себя импровизированную БД и содержит словари для хранения информации о фоновых задачах, объекты моделей, загруженных в память, и информацию о всех обученных моделях
9. `SERVICE/backend/dependency.py`
   Здесь находятся зависимости, внедряемые в эндпоинты
10. `SERVICE/backend/exceptions.py`
    Тут добавлены кастомные ошибки
11. `SERVICE/frontend/requirements.txt`
    Необходимые зависимости

Эндпоинты:

1. api/v1/models (trainer.py)
   - / (получение списка моделей и информации о них: обучены ли, выгружены ли, набор гиперпараметров)
   - /fit (запуск фоновой задачи обучения модели в фоне в отдельном процессе)
   - /load (добавление в пространство инференса указанной модели)
   - /unload (выгрузка указанной модели из инференса)
   - /predict (получение предсказаний при помощи указанной модели)
   - /predict_scores (predict_proba / decision_function для постройки ROC-кривых)
   - /remove (удаление* указанной модели из хранилища)
   - /remove_all (удаление* всех моделей из хранилища)

* - кроме моделей по умолчанию

2. api/v1/tasks (background_tasks.py)
   - / (получение списка задач с актуальными на момент запроса статусами)

Frontend (Streamlit)

Общее

Клиентская часть представляет собой мультистраничное Streamlit-приложение, реализующее следующий функционал в контексте задачи классификации токсичных комментариев:

- Разведочный анализ (визуализация признаков от текстовых данных в зависимости от метки класса: длина текста, части речи, частотность токенов/N-грамм, облака слов)
- Управление моделями машинного обучения (обучение, инференс, отслеживание задач на обучение, получение информации о доступных моделях)
- Сравнение моделей между собой на основе метрик качества
- Получение предсказаний

Техническая часть

Основные технические особенности:

- Контейнеризация
- Логирование
- Асинхронность
- Модульность
- Кэширование и session_state

Структура:

SERVICE/frontend/
```
|   ├── app_pages
|   |   ├── bg_tasks.py
|   |   ├── eda.py
|   |   ├── file_upload.py
|   |   ├── manage_models.py
|   |   ├── predict.py
|   |   ├── predict_scores.py
|   |   └── train_models.py
|   └── utils
|       ├── __init__.py
```

```
│       ├── client.py
│       ├── data_processing.py
│       └── streamlit_helpers.py
├── Dockerfile
├── requirements.txt
├── app.py
├── logger_config.py
```

Описание основных компонент:

12. `SERVICE/frontend/app.py`

    Entrypoint приложения, отвечающий за объединение страниц и маршрутизацию

13. `SERVICE/frontend/app_pages`

    Директория, содержащая модули, реализующие функционал различных страниц приложения:

    - `file_upload.py`: точка входа в приложение с точки зрения пользователя, интерфейс для загрузки данных для последующего обучения или аналитики
    - `eda.py`: разведочный анализ данных, визуализации
    - `manage_models.py`: управление хранящимися на сервере моделями машинного обучения
    - `train_models.py`: интерфейс для обучения новых моделей с выбором составляющих пайплайна и гиперпараметров
    - `bg_tasks.py`: просмотр состояния фоновых задач обучения моделей
    - `predict.py`: выполнение предсказаний при помощи выбранной модели
    - `predict_scores.py`: сравнение моделей на основе интегральных метрик качества

14. `SERVICE/frontend/utils`

    Вспомогательные модули

    - `client.py`: управление клиентскими запросами (взаимодействие с API).
    - `data_processing.py`: утилиты для различных проверок и преобразований данных
    - `streamlit_helpers.py`: функции для упрощения логики создания streamlit-объектов на основных страницах

15. `SERVICE/frontend/logger_config.py`

    Конфигурация и инстанцирование логгера

16. `SERVICE/frontend/Dockerfile`

    Описание Docker-образа для контейнеризации приложения
17. `SERVICE/frontend/requirements.txt`

    Необходимые зависимости

Логирование

При запуске контейнеров в директориях app/ создаются директории logs/backend и logs/frontend, в которых создаются файлы для сохранения логов. Эта директория проброшена в docker volume (как и директория с файлами моделей), так что логи сохраняться даже после остановки контейнеров.

Инфраструктура

Фронтенд и бэкенд работают в разных контейнерах, которые запускаются с помощью docker-compose.yml. В infra-dev/ находится файл для локального развертывания, в infra/ - для развертывания на сервере. Файл для прода отличается тем, что там образы подтягиваются с DockerHub, также там закрыты от внешнего мира порты бэкенда и фронтенда. Фронтенд и бэкенд скрыты за прокси NGINX, который перенаправляет запросы в нужный сервис. Также в дальнейшем планируется настройка ci-cd для автоматического обновления кода на сервере и добавление полноценной базы данных.

Приложение было развернуто на арендованном сервере, посмотреть его можно, перейдя на http://89.110.90.133/ . На данном этапе деплой производился руками, были добавлены на сервер файлы infra/docker-compose.yml, env-файл с переменными окружения и файл nginx.conf для конфигурации NGINX. Образы тянутся с DockerHub командой docker compose pull.
Взаимодействие с машиной происходило через SSH-соединение.

User Guide

Описание работы интерфейса(frontend)

Главной точкой входа в интерфейс является Вкладка **Homepage/data upload** вы загружаете файл csv с токсичными комментариями - обязательно наличие столбцов toxic и comment_text - после загрузки вы можете просмотреть dataframe загруженного файла(Мы просим по возможности использовать файл **demo_data_sample.csv** который лежит в корне папки SERVICE - для демонстрации работы проекта


Deploy
Home
Homepage/data upload
Models
Manage models
Train models
Predict
Compare models by ROC
Analytics
EDA
Tools
Monitor tasks
Toxic comments classification app
App for analyzing data, managing models and obtaining predicitions for the task of classificating toxic comments
Upload data to analyze/train model with
Drag and drop file here
Limit 10GB per file • CSV
Browse files
demo_data_2.csv 38.9MB
Data preview
comment_text
toxic
0
She probably went back to her pedophile protector site. Apologist Dave Pierre has a sick and twisted site "the media report." Apologists there have a goal to defend the indefensible and call themselves traditional Catholics. I am angered and sickened by the lies and disrespect the media report has shown to my personal hero, Tom Doyle. If I met Pierre on the street, I am afraid that I could not control my emotions, but would gladly spend a few days in the Graybar hotel to give him the what for about his lies and remarks about Tom Doyle. I call this kind of act, traditional Irish Catholic problem resolution. (even though I am Polish) Pierre represents Tom Doyle as a villain and a traitor to the church. He calls Tom a liar and a fraud. Pandora fits right in
1

Далее во вкладке **Train models** вы можете обучить одну из доступных типов моделей с гиперпараметрами которые подходят для выбранной модели(Logistic Regression, LinearSvc, Naive Bayes)

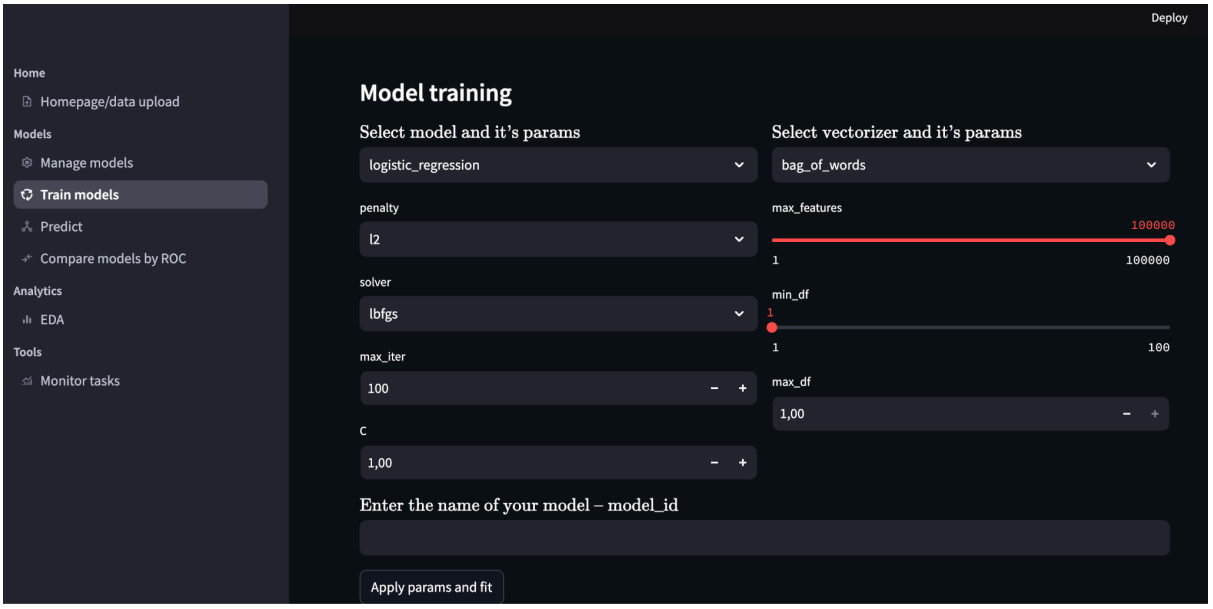

После запуска обучения вы можете мониторить текущие задачи обучения во вкладке **Monitor tasks**

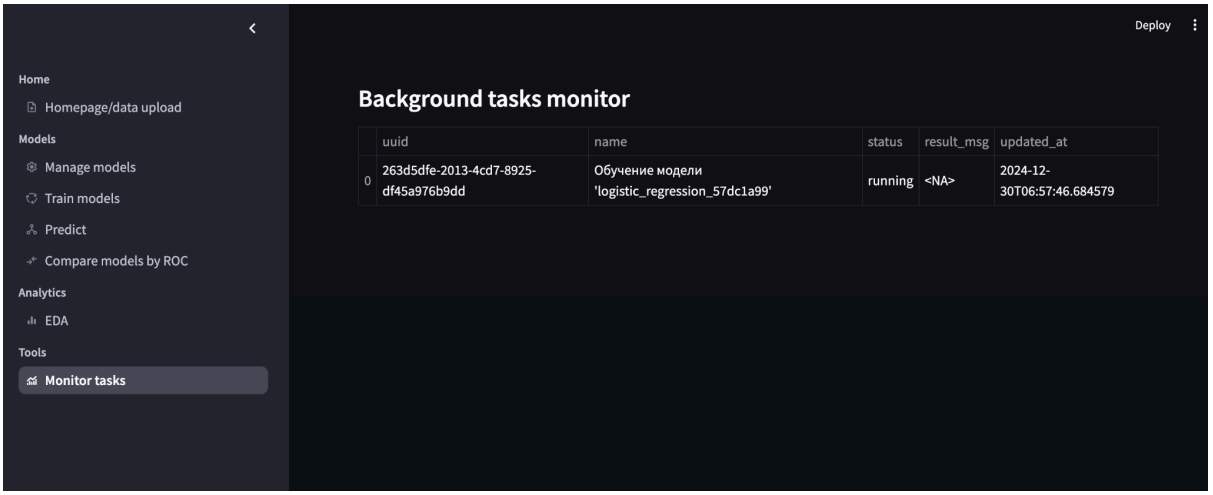

Во вкладке **Manage models** вы можете управлять текущими моделями(удалять модель, загружать инференс и выгружать инференс модели, удалять все модели)

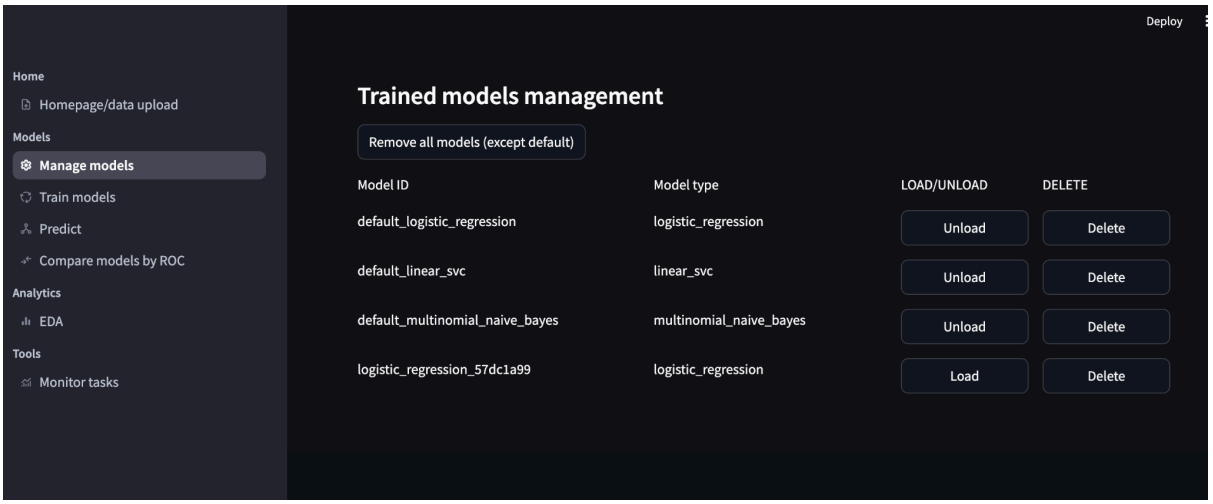

Во вкладке **EDA** вы можете получить аналитику по ранее загруженному csv - иногда возможна долгая обработка и подготовка аналитики

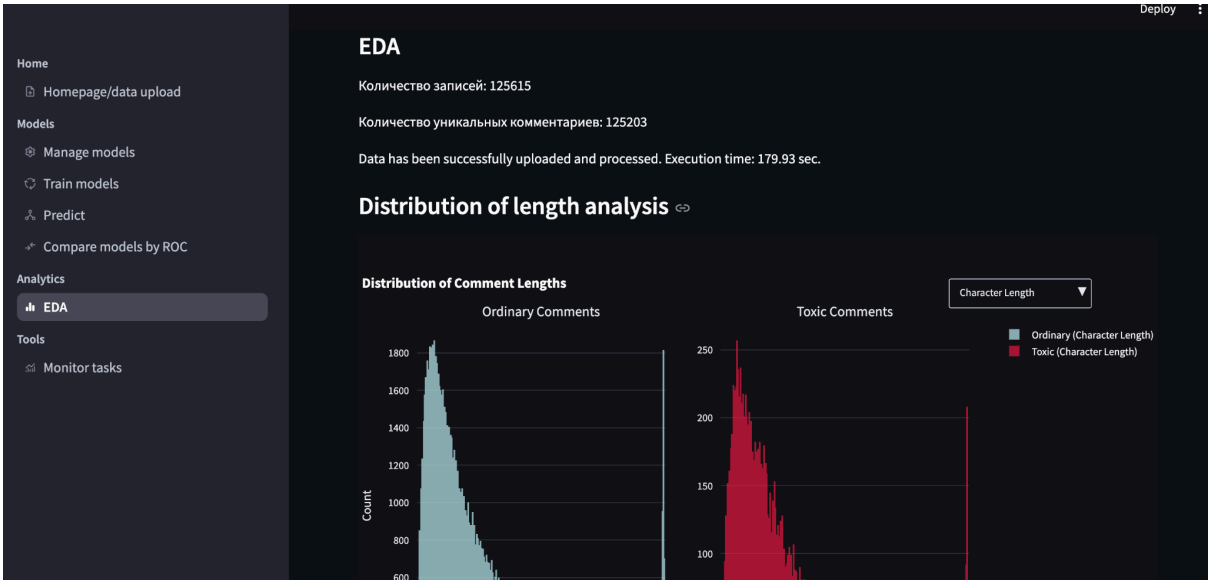

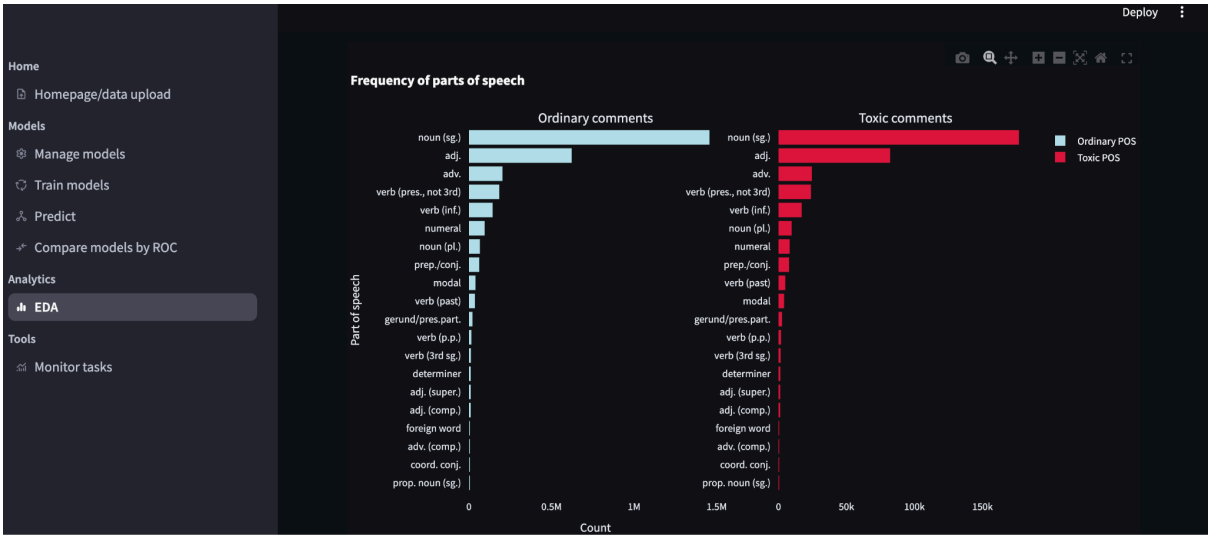

Во вкладке **Predict** вы можете получить предсказанное значение токсичности комментария если передадите текст в textarea - очень важно передавать строку без переносов в textarea иначе она будет считана некорректно

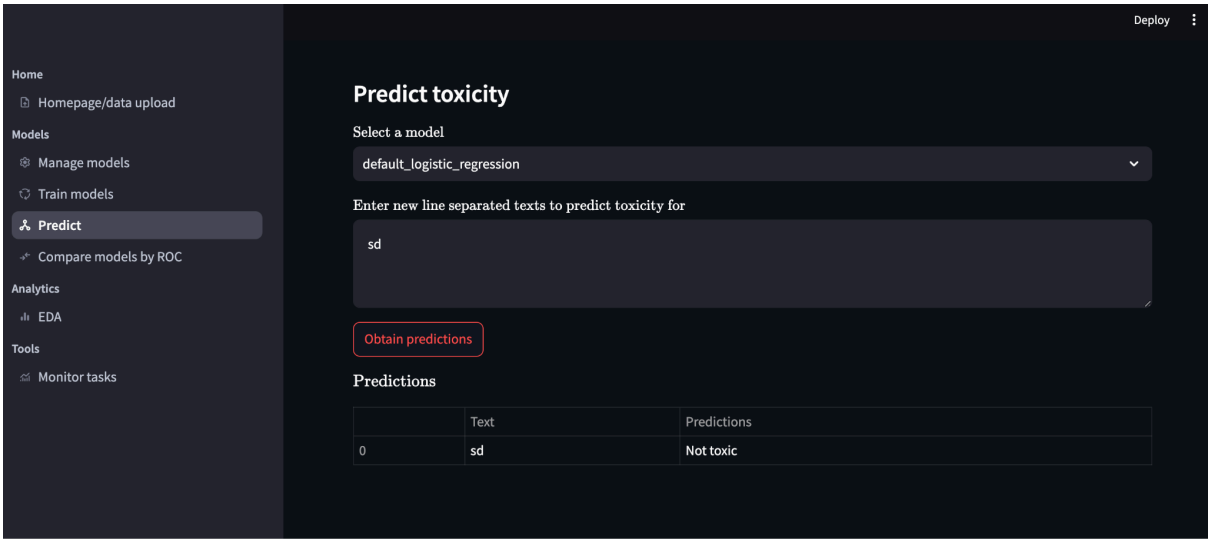

Во вкладке **Compare models by ROC** вы можете выбрать одну или несколько моделей для построение метрик и выбора наилучшей модели - в рамках интерфейса вы можете использовать как существующий файл(который ранее был загружен в главной вкладке) выбрал галочку **Use previous (train) data** так и загрузить свой собственный (убрав эту галочку) для построения графиков нажмите кнопку “Построить графики”

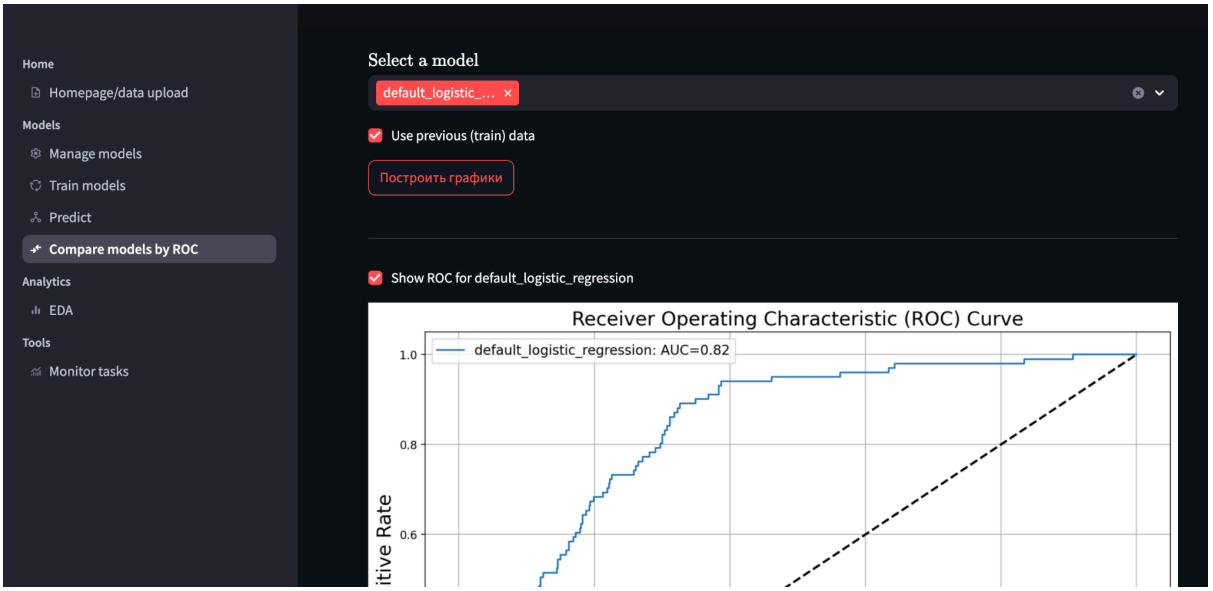
Home
Homepage/data upload
Models
Manage models
Train models
Predict
Compare models by ROC
Analytics
EDA
Tools
Monitor tasks
Select a model
default_logistic_...
Use previous (train) data
Построить графики
Show ROC for default_logistic_regression
Receiver Operating Characteristic (ROC) Curve
default_logistic_regression: AUC=0.82
1.0
0.8
0.6
itive Rate

Docker

В рамках сервиса реализовали докеризацию проекта - создали 2 контейнера backend и frontend. Использованы собственные Dockerfile для сборки каждого контейнера.

Для сборки и запуска контейнеров локально нужно в директории SERVICE/infra-dev/ создать файл .env и поместить туда переменные из .env.dev.template, затем выполнить:

docker compose up -d

Деплой на сервер

Сервис развернут на сервере - развернутый сервис можно найти по следующему адресу http://89.110.90.133/